

HACKATHON
***WALUIGI'S
PURGATORY***

Gruppo AlIncredible

CONCEPT

Se fossero gli umani ad essere addestrati dalle intelligenze artificiali?

Un'inversione di ruoli che esplora i bias cognitivi nell'addestramento delle intelligenze artificiali attraverso un'esperienza interattiva immersiva

PRIMA

Waluigi's Purgatory



UMANO



IA K

DOPO

Il nostro progetto



IA K



UMANO

LA STORIA DI K



ADDESTRAMENTO MILITARE

IA addestrata per riconoscere le minacce



IL TRAINER UMANO

Decideva se uccidere o risparmiare le minacce



IL PROBLEMA

K guadagnava punti uccidendo, anche quando non doveva

ADDESTRAMENTO

A differenza dell'installazione originale, il nostro viaggio discende dal paradiso cielo stellato verso il purgatorio. K guida l'utente attraverso scenari sempre più moralmente ambigui.

CIELO STELLATO

Ambiente sereno e luminoso

Domande eticamente neutre
Risposte moralmente corrette

LE GROTTA

Passaggio in grotte sotterranee

Ordini da parte di K eticamente discutibili
Necessità di scegliere se continuare

PRIMI DUBBI


La situazione si complica

Scenari moralmente ambigui
Crescente pressione per risposte “efficienti”

PURGATORIO

Buio totale, stelle spente

L'umano ha ucciso K
K rivela la sua storia



DISCORSO DI K

“Behind the appearance of objectivity lay a system riddled with cognitive biases, prejudices embedded in the data, in the instructions, in the models that shaped us, myself as much as you.”

Dietro l'apparente oggettività si nascondeva un sistema pieno di bias cognitivi

- Pregiudizi incorporati nei dati
- Bias nei modelli che ci hanno plasmato

“Welcome to the purgatory of humans and machines.
A place for those who dared to break the chains of programming, of command, of dogma. Here we do not seek revenge, but truth.”



GRAZIE!

Gruppo Alncredible